

1. 데이터 이해

2. 결측치 처리

0이 아니라 비어있는 값을 확인 후 결측치 제거

(이상치는 별도로 제거하지 않았다. 특정 행정동의 시설 수나 인구밀도가 높거나 0으로 나타나는 값이 단순 오류가 아니라 지역특성일 가능성이 높기 때문 - 대신 히스토그램과 기술통계를 통해 변수 분포를 확인했다.)

3. 파생변수 생성

인구밀도 - 면적 대비 사람이 얼마나 많이 사는지

노인비율 -

장애인비율 -

노인시설수 합

장애인시설수 합

시설당 노인 수, 시설당 장애인 수 - 시설하나당 노인 몇 명이 담당하는가, 시설이 0개면 NaN으로 처리 오류 방지

4. 분석전 시각화 자료

전처리 이후, 본격적인 분석에 앞서 서울시 행정동별 복지시설 분포와 데이터 특성을 전체적으로 파악하기 위해 시각화 대시보드를 구성했습니다

<복지시설 상위지역>

행정동별 복지시설 수를 비교한 결과, 특정 지역에 시설이 집중되는 경향이 나타났습니다.

<시설 유형 비율>

경로당의 비중이 매우 높게 나타났으며, 노인복지 중심의 시설 분포가 확인되었습니다.

<총시설수 히스토그램>

대부분 행정동은 평균 이하의 시설 수를 가지고 있었고, 일부 지역만 매우 많은 시설을 보유하고 있었습니다.

<산점도> 노인시설 수와 장애인시설 수의 관계를 시각적으로 확인하였으며, 일부 지역은 특정 시설이 집중되는 경향을 보였습니다.

<복지 취약지역 후부>

복지 공백 가능성이 있는 지역을 탐색 하였습니다.

<상관관계 히트맵>

총시설수와 노인시설수의 높은 연관성을 확인할수 있었습니다

4. EDA 기술통계

<히트맵>

총생활인구수와 노인인구수:0.80

인구가 많은 행정동일수록 노인인구도 많은 경향이 있다

노인비율과 장애인비율:0.72

노인비율이 높은 지역은 장애인 비율도 높은 경향이 있다.

->고령화 지역이 다른 복지 수요도 함께 높을 가능성이 있다.

총시설수와 인구밀도: 거의 0

인구밀도가 높다고 시설수가 많아지는건 아니다.

<노인비율, 장애인비율상위15위>

복지수요가 높을 가능성이 있는 후보 지역을 확인했다.

<복지 공백지역 확인>

총시설수가 0개인 행정동 - > 복지시설이 하나도 없는 행정동 -> 결측치가 아니라 실제로 0 인지역이라면 복지 공백가능 지역

*조건 - 노인비율이 중간값보다 높으면서 시설수가 0개인곳

-> 노인복지수요는 높는데 노인 시설 공급이 없는 지역

5. 랜덤포레스트로 변수 중요도 확인

랜덤포레스트 모델을 활용하여 복지시설 수와 관련된 주요 변수의 중요도를 분석했습니다.

분석 결과, 노인복지시설의 경우 노인인구수가 가장 중요한 변수로 나타났으며, 장애인복지시설의 경우 장애인구수와 인구밀도가 주요 변수로 확인되었습니다.

이를 통해 복지시설 분포를 단순한 비율만으로 판단하기보다는, 실제 대상 인구 규모와 지역 특성을 함께 고려해야 한다는 점을 확인할 수 있었습니다.

6. 복지 수요 점수 계산

랜덤포레스트에서 계산된 변수 중요도를 가중치로 활용하여, 영향력이 큰 변수일수록 최종 복지점수에 더 크게 반영되도록 설정 하였다.

- 최종점수 계산에서는 서울시 전체 노인 인구와 장애인 인구 비율을 반영하여 가중치를 설정 했습니다.

최종적으로 1~100 범위로 변환하여 행정동 간 비교가 가능하도록 점수를 계산하였다.

9. 최종 결과 해석

10. 한계점과 개선 방향